


Ajuste de Curvas

(e em particular, Regressão Linear)

Fabricio Murai


Exemplo de ajuste de curva

- Quero encontrar uma função que relaciona x e y
- A função deve capturar a tendência, mas não precisa passar necessariamente pelos pontos
- Temos que assumir uma "cara" para essa função




Exemplo de ajuste de curva

- Assuma, por exemplo, $f(x) = ax+b$ (poderíamos ter escolhido outra)
- Queremos encontrar parâmetros a e b que **melhor** ajustam a curva aos dados
- Como definir **melhor** ajuste?



Como medir a qualidade em um ponto x ?



Erro absoluto:

$$d_i = |\hat{y}_i - y_i|$$

Erro quadrático:

$$d_i = (\hat{y}_i - y_i)^2$$

Qualidade do ajuste



Exemplos de métricas levando em consideração pontos $(x_1, y_1), \dots, (x_n, y_n)$:

1. Erro máximo $E_\infty = \max_{i=1, \dots, n} |\hat{y}_i - y_i|$

2. Erro médio (Erro L_1) $E_1 = \frac{1}{n} \sum_{i=1, \dots, n} |\hat{y}_i - y_i|$

3. Raiz do erro quadrático médio (Erro L_2) $E_2 = \sqrt{\frac{1}{n} \sum_{i=1, \dots, n} (\hat{y}_i - y_i)^2}$

Relação entre métrica de erro e outliers (pontos "fora da curva")



Justificativa para o uso de E_2

Embora o erro médio absoluto E_1 seja mais robusto a outliers, a função módulo não possui derivada contínua.

Já (raiz do) erro médio quadrático é um bom compromisso: relativamente robusto e possui derivada contínua.

Ajuste de curvas visando minimizar (raiz do) erro médio quadrático é conhecido por **Método dos Quadrados Mínimos**.

Método dos Quadrados Mínimos (MQM)

O MQM consiste em encontrar os parâmetros da função f que minimizam o erro

$$E_2 = \sqrt{\frac{1}{n} \sum_{i=1, \dots, n} (\hat{y}_i - y_i)^2}$$

Isto é equivalente a minimizar


$$D(f) = \sum_{i=1, \dots, n} (\hat{y}_i - y_i)^2$$

Método dos quadrados mínimos

Exemplo 1: $f(x) = b_1 x$

$$\begin{aligned} D(b_1) &= \sum_{k=1}^n (f(x_k) - y_k)^2 \\ &= \sum_{k=1}^n (b_1 x_k - y_k)^2 \\ &= \sum_{k=1}^n [b_1^2 x_k^2 - 2b_1 x_k y_k + y_k^2] \\ &= b_1^2 \sum_{k=1}^n x_k^2 - 2b_1 \sum_{k=1}^n x_k y_k + \sum_{k=1}^n y_k^2 \end{aligned}$$

Qual a "cara"
desta função?



Método dos quadrados mínimos


Exemplo 1: $f(x) = b_1 x$

A função que queremos minimizar é $D(b_1) = b_1^2 \sum_{k=1}^n x_k^2 - 2b_1 \sum_{k=1}^n x_k y_k + \sum_{k=1}^n y_k^2$

Para isso, queremos encontrar b_1 onde a $D(b_1)$ a derivada é nula.

$$\frac{dD}{db_1} = 2b_1 \sum_{k=1}^n x_k^2 - 2 \sum_{k=1}^n x_k y_k = 0$$

$$\Rightarrow b_1 = \frac{\sum_{k=1}^n x_k y_k}{\sum_{k=1}^n x_k^2}$$



Método dos quadrados mínimos

Exemplo 2: $f(x) = b_0 + b_1 x$

$\min D(b_0, b_1)$, onde


$$D(b_0, b_1) = \sum_{k=1}^n (f(x_k) - y_k)^2 = \sum_{k=1}^n (b_0 + b_1 x_k - y_k)^2$$

$$\frac{dD}{db_0} = \sum_{k=1}^n 2(b_0 + b_1 x_k - y_k) = 0$$

$$\Rightarrow b_0 \sum_{k=1}^n 1 + b_1 \sum_{k=1}^n x_k = \sum_{k=1}^n y_k$$

$$\frac{dD}{db_1} = \sum_{k=1}^n 2(b_0 + b_1 x_k - y_k)x_k = 0$$

$$\Rightarrow b_0 \sum_{k=1}^n x_k + b_1 \sum_{k=1}^n x_k^2 = \sum_{k=1}^n y_k x_k$$



Método dos quadrados mínimos

Exemplo 2: $f(x) = b_0 + b_1 x$

$$b_0 n + b_1 \sum_{k=1}^n x_k = \sum_{k=1}^n y_k$$

$$b_0 \sum_{k=1}^n x_k + b_1 \sum_{k=1}^n x_k^2 = \sum_{k=1}^n y_k x_k$$

Como encontrar
 b_0 e b_1 ?

Método dos quadrados mínimos

Exemplo 2: $f(x) = b_0 + b_1 x$

Como encontrar
 b_0 e b_1 ?

$$b_0 n + b_1 \sum_{k=1}^n x_k = \sum_{k=1}^n y_k$$

$$b_0 \sum_{k=1}^n x_k + b_1 \sum_{k=1}^n x_k^2 = \sum_{k=1}^n y_k x_k$$

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}.$$

Método dos quadrados mínimos

Exemplo 3: $f(x) = b_0 e^{b_1 x}$

$$D(b_0, b_1) = \sum_{i=1}^n (b_0 e^{b_1 x_i} - y_i)^2$$

$$\frac{\partial D}{\partial b_0} = \sum_{i=1}^n 2(b_0 e^{b_1 x} - y_i) e^{b_1 x} = 0$$

$$\frac{\partial D}{\partial b_1} = \sum_{i=1}^n 2(b_0 e^{b_1 x} - y_i) b_0 b_1 e^{b_1 x} = 0$$

Dá origem a um sistema de equações não-lineares

Generalizando

Relacionamos $x \in \mathbb{R}$ com $y \in \mathbb{R}$ através de $f(x)$. Chamamos:

- x de **preditor** ou variável independente
- y de **resposta** ou variável dependente

No caso geral, podemos ter um conjunto de preditores representado por um vetor $\mathbf{x}_i = [x_{i1}, x_{i2}, \dots, x_{in}]$. Assim, $f(\mathbf{x}): \mathbb{R}^n \rightarrow \mathbb{R}$.

Exemplo: imóveis (\mathbf{x}_i, y_i) , onde $\mathbf{x}_i = [\text{num_quartos}_i, \text{area}_i]$, $y = \text{preço}_i$
$$f(\mathbf{x}) = b_0 + b_1 x_{i1} + b_2 x_{i2}$$

Método dos quadrados mínimos

Podemos escolher outras funções também. Quando estas funções são lineares nos parâmetros b_0, b_1, \dots, b_p , o MQM dá origem a um sistema de equações lineares.

Quiz: funções lineares nos parâmetros?

Aula anterior

- Regressão Linear
 - Simples
 - Múltipla
 - Polinomial
- Estimando coeficientes da regressão linear pelo MQM

Aula de hoje

- Linearização
- Complexidade do MQM
- Condicionamento de $X^T X$
- Obtendo estimadores de quadrados mínimos sem construir equações normais
 - Decomposição QR
- Visão geral do conteúdo da Prova 2

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow$$

$$y = ab^x \rightsquigarrow$$

$$y = ae^{bx} \rightsquigarrow$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) =$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow$$

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow$$

$$y = ae^{bx} \rightsquigarrow$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) =$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow$$

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow \log_e(y) = \log_e(a) + \log_e(b)x;$$

$$y = ae^{bx} \rightsquigarrow$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) =$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow$$

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow \log_e(y) = \log_e(a) + \log_e(b)x;$$

$$y = ae^{bx} \rightsquigarrow \log_e(y) = \log_e(a) + bx;$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) =$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow$$

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow \log_e(y) = \log_e(a) + \log_e(b)x;$$

$$y = ae^{bx} \rightsquigarrow \log_e(y) = \log_e(a) + bx;$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow \log_e(y) = a + bx_1 + cx_2;$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) =$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow$$

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow \log_e(y) = \log_e(a) + \log_e(b)x;$$

$$y = ae^{bx} \rightsquigarrow \log_e(y) = \log_e(a) + bx;$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow \log_e(y) = a + bx_1 + cx_2;$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x_1) + c \log_e(x_2)$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow$$

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow \log_e(y) = \log_e(a) + \log_e(b)x;$$

$$y = ae^{bx} \rightsquigarrow \log_e(y) = \log_e(a) + bx;$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow \log_e(y) = a + bx_1 + cx_2;$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x_1) + c \log_e(x_2)$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow \frac{1}{y} = a + bx_1 + cx_2;$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow$$

Linearização

Alguns modelos não-lineares nos parâmetros podem ser transformados em modelos lineares

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow \log_e(y) = \log_e(a) + \log_e(b)x;$$

$$y = ae^{bx} \rightsquigarrow \log_e(y) = \log_e(a) + bx;$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow \log_e(y) = a + bx_1 + cx_2;$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x_1) + c \log_e(x_2)$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow \frac{1}{y} = a + bx_1 + cx_2;$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow \log_e \left(\frac{1}{y} - 1 \right) = a + bx_1 + cx_2.$$

Complexidade

A estimação dos parâmetros de uma regressão linear pelo método que vimos em sala requer dois passos:

1. Construção das **equações normais** $X^T X \beta = X^T y$
2. Solução do sistema

Qual o custo de cada uma dessas etapas?

Custo de construção das equações normais

Sejam:

p : # parâmetros

n : # observações

A matriz $X^T X$ é $(p \times p)$. O cálculo de cada entrada da matriz requer n adições e n multiplicações. Logo, o custo total é $\Theta(p^2 n)$.

Note que o custo cresce linearmente no número de observações.

Custo de solução das equações normais

Quando as colunas de X são LI, $X^T X$ é simétrica e definida positiva. Uma possibilidade seria resolver por Cholesky, cujo custo é $\Theta(p^3)$.

Em geral, $n > p$ e, portanto, o custo de construção e solução somados são $\Theta(p^3 + p^2 n) = \Theta(p^2 n)$.

Normalmente, o problema deste método não é o custo computacional, mas sim o condicionamento de $X^T X$.

Condicionamento de $X^T X$

Considere o número de condição segundo a norma-2.

$$\kappa(X^T X) = \frac{\lambda_{\max}(X^T X)}{\lambda_{\min}(X^T X)}$$

Condicionalamento de $X^T X$

Considere o número de condição segundo a norma-2.

$$\kappa(X^T X) = \frac{\lambda_{\max}(X^T X)}{\lambda_{\min}(X^T X)}$$

$$\lambda_{\max}(X^T X) = \sigma_{\max}^2(X) \quad \text{e} \quad \lambda_{\min}(X^T X) = \sigma_{\min}^2(X)$$

$$\kappa(X^T X) = \left(\frac{\sigma_{\max}(X)}{\sigma_{\min}(X)} \right)^2$$

Condicionamento de $X^T X$

Considere o número de condição segundo a norma-2.

$$\kappa(X^T X) = \frac{\lambda_{\max}(X^T X)}{\lambda_{\min}(X^T X)}$$

$$\lambda_{\max}(X^T X) = \sigma_{\max}^2(X) \quad \text{e} \quad \lambda_{\min}(X^T X) = \sigma_{\min}^2(X)$$

$$\kappa(X^T X) = \left(\frac{\sigma_{\max}(X)}{\sigma_{\min}(X)} \right)^2$$

Ex...: Quando $k(X)=10^3$,
 $k(X^T X)=10^6$